

Procesamiento de Lenguaje Natural

1er Semestre 2026


Luciano Del Corro

*UDES*A

Objetivos

- Comprender los fundamentos y la arquitectura interna de los LLMs.
- Dominar los pasos y buenas prácticas para diseñar, entrenar y optimizar un asistente.
- Desarrollar habilidades de ingeniería para construir soluciones avanzadas de NLP.
- Adquirir las competencias para superar entrevistas técnicas en academia e industria.

Programa



Trabajo Práctico

Cronograma

Clase	Fecha	Teoría
Clase 1	10/3/2026	Embeddings: Codificando el Lenguaje
Clase 2	17/3/2026	Introducción a Modelos de Lenguaje: N-gramas y Primeros Modelos Neuronales
Clase 3	24/03/2026	FERIADO
Clase 4	31/03/2026	ELMo: LSTMs y Redes Neuronales Recurrentes
Clase 5	7/4/2026	BERT: Atención, Transformers, Encoders y Decoders
Clase 6	14/4/2026	GPT: Preentrenamiento y Modelos Generativos
Clase 7	21/4/2026	ChatGPT: RLHF, DPO e Instruction Tuning
Clase 8	28/04/2026	Reasoning -- Repaso
Clase 9	05/05/2026	Repaso
Clase 10	12/5/2026	Examen
Clase 11	19/5/2026	Introducción a Agentes
Clase 12	26/5/2026	Presentaciones

Organización

Clases Teóricas

- Jueves, de 16:30 a 19:40.

Material de Clase

- Se entregarán las slides luego de cada sesión.
- Antes del examen se reparte una guía de unas 100 preguntas.
- Cada clase tiene lecturas optativas.
- Los alumnos recibirán un Colab por clase que deberán trabajar y entender en sus casas.

Evaluación

- **Examen:** 50%
- **Engineering Project:** 50%

Proyecto a Elección

- El tema TP es elegido por el estudiante con la aprobación del equipo docente. Se evalúa con una presentación. Los alumnos deberán presentar un repositorio de Github con el proyecto.

Requisitos de Aprobación

- Aprobar el **Examen** (recuperatorio al final del semestre), el **Research Project** o el **Engineering Project**.
- Obtener un **promedio ponderado** (en todas las instancias de evaluación) **mayor o igual a 4**.

Los proyectos son de elección libre y se evalúan caso por caso. Algunos aspectos generales:

- **Metodología:** Rigurosidad, definición del problema, formulación de hipótesis.
- **Estado del Arte:** Comprensión de metodologías y modelos existentes.
- **Diseño de Solución:** Pertinencia de técnicas y herramientas.
- **Datos:** Selección, manejo y obtención.
- **Diseño Experimental:** Calidad de experimentos y técnicas de evaluación.
- **Implementación:** Buenas prácticas y reproducibilidad.
- **Análisis:** Interpretación de resultados y limitaciones.
- **Presentación y Comunicación**

Engineering Project: Sistema, solución, aplicación o research

Diseño, implementación y deployment de un sistema funcional que resuelva un problema real usando técnicas de NLP.

¿Qué es?

Un sistema end-to-end con múltiples componentes: puede ser un chatbot, un agente autónomo, un recomendador de música, un asistente legal, un pipeline de datos — lo que la imaginación permita.

Entregable: Repositorio de Git + especificación del sistema/producto.

Aspectos de evaluación:

- **Arquitectura:** Diseño del sistema, componentes, interacción entre módulos.
- **Funcionalidad:** El sistema funciona, resuelve el problema planteado.
- **Stack técnico:** Uso apropiado de APIs, frameworks, modelos y herramientas.
- **Eficiencia y Costo:** Optimización de recursos, decisiones costo-beneficio, latencia.
- **UX/Interfaz:** El usuario puede interactuar con el sistema de forma clara.
- **Robustez:** Manejo de errores, edge cases, escalabilidad básica.
- **Deployment:** El sistema corre — demo en vivo, Docker, API pública, o equivalente.
- **Documentación:** README, instrucciones de uso, repositorio limpio en Github.



El único límite es la imaginación.

Research Project: Trabajo de naturaleza científica

Investigación original sobre un tema de NLP/LLMs con rigor académico.

Aspectos de evaluación:

- **Metodología:** Rigurosidad, problema, hipótesis.
- **Estado del Arte:** Trabajos existentes.
- **Diseño Experimental:** Experimentos y evaluación.
- **Análisis:** Resultados y limitaciones.
- **Presentación:** Comunicación clara, formato ACL.
- **Repositorio Github:** Código y datos.

Instructions for *ACL Proceedings

Anonymous ACL submission

001 **Abstract** To load the style file in the review version: 036

002 This document is a supplement to the general \usepackage[review]{acl} 037

003 instructions for *ACL authors. It contains in- For the final version, omit the review option: 038

004 structions for using the L^AT_EX style files for \usepackage{acl} 039

005 ACL conferences. The document itself con- To use Times Roman, put the following in the 040

006 forms to its own specifications, and is therefore preamble: 041

007 an example of what your manuscript should \usepackage{times} 042

008 look like. These instructions should be used (Alternatives like txfonts or newtx are also accept- 043

009 both for papers submitted for review and for able.) 044

010 final versions of accepted papers. Please see the L^AT_EX source of this document for 045

011 **1 Introduction** comments on other packages that may be useful. 046

012 These instructions are for authors submitting pa- Set the title and author using \title and 047

013 pers to *ACL conferences using L^AT_EX. They \author. Within the author list, format multiple 048

014 are not self-contained. All authors must follow the authors using \and and \AND; please see 049

015 general instructions for *ACL proceedings,¹ and this the L^AT_EX source for examples. 050

016 document contains additional instructions for the By default, the box containing the title and au- 051

017 L^AT_EX style files. thor names is set to the minimum of 5 cm. If 052

018 The templates include the L^AT_EX source of this you need more space, include the following in the 053

019 document (acl_latex.tex), the L^AT_EX style file preamble: 054

020 used to format it (acl.sty), an ACL bibliography \setlength{titlebox{<dim>} 055

021 style (acl_natbib.bst), an example bibliography where <dim> is replaced with a length. Do not set 056

022 style (acl_natbib.bst), and the bibliography for the ACL this length smaller than 5 cm. 057

023 Anthology (anthology.bib). **4 Document Body** 058

024 **2 Engines** **4.1 Footnotes** 059

025 To produce a PDF file, pdfL^AT_EX is strongly recom- Footnotes are inserted with the \footnote com- 060

026 mended (over original L^AT_EX plus dvips+ps2pdf mand.² 061

027 or dvi2pdf). The style file acl.sty can also be **4.2 Tables and figures** 062

028 used with luaL^AT_EX and XeL^AT_EX, which are es- See Table 1 for an example of a table and its caption. 063

029 pecially suitable for text in non-Latin scripts. The Do not override the default caption sizes. 064

030 file acl_luaLatex.tex in this repository provides As much as possible, fonts in figures should 065

031 an example of how to use acl.sty with either conform to the document fonts. See Figure 1 for 066

032 luaL^AT_EX or XeL^AT_EX. an example of a figure and its caption. 067

033 **3 Preamble** ¹<http://acl-org.github.io/ACL/PUB/formatting.html> 068

034 The first line of the file must be ²This is a footnote. 069



035 \documentclass[11pt]{article} 070

El ideal de la representación simbólica

Maquinas que razonan como humanos

Representación y manipulación de símbolos para modelar y razonar sobre información textual

An ideal world



• **S: (v) be born** (come into existence through birth) "She was born on a farm"

S: (v) die decrease, perish, go, exit, pass away, expire, pass, kick the bucket, or one's chair, buy the farm, sink, give up the ghost, drop dead, pop off, choke, or snuff it (pass from physical life and lose all bodily attributes and functions neces- to sustain life) "She died from cancer"; "The children perished in the fire"; "The patient went peacefully"; "The old guy kicked the bucket at the age of 102"

De la representación Simbólica a Embeddings

La Transformación en la Representación del Lenguaje


“Albert Einstein was born in Germany. He died in Princeton.”



a_{00}	a_{01}	a_{02}	a_{03}	a_{04}	a_{05}	a_{06}	a_{07}
a_{10}	a_{11}	a_{12}	a_{13}	a_{14}	a_{15}	a_{16}	a_{17}
a_{20}	a_{21}	a_{22}	a_{23}	a_{24}	a_{25}	a_{26}	a_{27}
a_{30}	a_{31}	a_{32}	a_{33}	a_{34}	a_{35}	a_{36}	a_{37}
a_{40}	a_{41}	a_{42}	a_{43}	a_{44}	a_{45}	a_{46}	a_{47}
a_{50}	a_{51}	a_{52}	a_{53}	a_{54}	a_{55}	a_{56}	a_{57}
a_{60}	a_{61}	a_{62}	a_{63}	a_{64}	a_{65}	a_{66}	a_{67}
a_{70}	a_{71}	a_{72}	a_{73}	a_{74}	a_{75}	a_{76}	a_{77}
a_{80}	a_{81}	a_{82}	a_{83}	a_{84}	a_{85}	a_{86}	a_{87}
a_{90}	a_{91}	a_{92}	a_{93}	a_{94}	a_{95}	a_{96}	a_{97}


- Los embeddings **codifican conocimiento** en espacios de alta dimensión,
- Capturar relaciones y significado **sin necesidad de esquemas rígidos y con menos complejidad**
- Facilita el manejo de **grandes volúmenes de datos** y la variabilidad del lenguaje humano.
- Aprendizaje continuo, y transferencia de conocimiento**

- Más **tolerantes a i** y conflictos en




Modelos de Lenguaje, Embeddings y Redes Neuronales

$$p(x_1^n) = \prod_{k=1}^N p(w_k | w_1^{k-1})$$



- Introducción a modelos de lenguaje
- Modelos de lenguaje unidireccionales
- Introducción al transfer learning
- Primeros modelos neuronales y embeddings pre entrenados



Neural LM



Mikolov et. al., Efficient Estimation of Word Representations in Vector Space ,
2013

La Revolución del Deep Learning en NLP: El Auge de las Bi-LSTM


- **Generalización con Embeddings Preentrenados:** Al emplear embeddings preentrenados en la inicialización de token embeddings se logra una convergencia más rápida y mejor generalización.
- **Dominio de las Arquitecturas Bi-LSTM:** La arquitectura Bi-LSTM se convirtió en la más popular, debido a su eficacia y capacidad para capturar información contextual en ambas direcciones del texto



Preentrenamiento, ELMO y embeddings contextuales



- **El preentrenamiento** implica entrenar toda la red en un gran corpus (e.g., la web) en una tarea general (e.g., predecir palabras en una oración).
- **Transferencia de conocimiento:** El preentrenamiento facilita la transferencia de conocimiento desde tareas generales de modelado del lenguaje a tareas específicas.
- **Reduce el tiempo y recursos computacionales** necesarios para entrenar modelos en tareas específicas.
- Resultado: se generan **embeddings contextuales**, no específicos a una palabra aislada sino en contexto.




TASK	PREVIOUS SOTA		OUR BASELINE	ELMo + BASELINE	INCREASE (ABSOLUTE/ RELATIVE)
SQuAD	Liu et al. (2017)	84.4	81.1	85.8	4.7 / 24.9%
SNLI	Chen et al. (2017)	88.6	88.0	88.7 $\pm$ 0.17	0.7 / 5.8%
SRL	He et al. (2017)	81.7	81.4	84.6	3.2 / 17.2%
Coref	Lee et al. (2017)	67.2	67.2	70.4	3.2 / 9.8%
NER	Peters et al. (2017)	91.93 $\pm$ 0.19	90.15	92.22 $\pm$ 0.10	2.06 / 21%
SST-5	McCann et al. (2017)	53.7	51.4	54.7 $\pm$ 0.5	3.3 / 6.8%


Transformers, BERT y la era de la Atención en NLP



- Arquitectura que introduce el **mecanismo de atención**; permite el **procesamiento en p**
- Self-Attention**: Cada palabra “ve” a todas las otras palabras en el contexto y decide ponderaciones.
- BERT ac



isfo



direccionales

Vaswani et. al.,
Attention is all you
need, 2018.

Devlin et. Al.,
BERT: Pre-training
of deep
bidirectional
transformers for
language
understanding

Unidad 5: BERT: Atención, Transformers, Encoders y Decoders

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT _{BASE}	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	92.7	94.9	60.5	86.5	89.3	70.1	82.1



GPT Modelos Autoregresivos basados en Transformers

- GPT (Generative Pre-trained Transformer): Diseñada para **generar texto**.
- **Entrenamiento autoregresivo**: Predice la siguiente palabra, condicionada por las palabras anteriores
- Mostró la capacidad de generar texto de **alta calidad, coherente y contextualmente relevante**.
- GPT-2 fue un indicio de las **capacidades emergentes en la escalabilidad. Zero shot sin fine**

$$p(x) = \prod_{i=1}^n p(s_i | s_1, \dots, s_{i-1})$$

Unidad 6: GPT: Pretraining y modelos Generativos

Revela el potencial de
OpenAI GPT




R:

Radford et. al, Improving language understanding by generative pre-training, 2018

GPT-3/4: Escalabilidad, Zero-shot y Capacidades Emergentes

- **Escalabilidad** en GPT-3: Modelo con 175 mil millones de parámetros
- **Zero-shot**: Realiza tareas sin entrenamiento adicional, utilizando el conocimiento previo del preentrenamiento.
- **Propiedades emergentes**: Capacidad de “razonamiento” entiende las tareas a realizar sin entrenamiento específico (escribir código, historias, responder preguntas, traducir, etc.).
- **Alucinación y Sesgos**: Pueden generar información incorrecta o inventada, sesgada al entrenamiento
- Sensibilidad a la formulación del **prompt** y falta de garantía.

- **Costo de ejecución**: El entrenamiento de modelos de gran escala como GPT-3 puede ser costoso en términos de recursos



los de gran escala como GPT-3 puede ser costoso


Language Models are Few-Shot Learners, Brown et. al. 2020

GPT-4 Technical Report, OpenAI, 2023

ChatGPT, Instructions and RLHF

Unidad 7: ChatGPT: RLHF, DPO e Instruction Tuning



- ChatGPT: Diseñado para superar la dificultad en controlar la generación de los modelos autoregresivos para mantener conversaciones naturales, entendiendo y respondiendo a instrucciones del usuario.
- Reinforcement Learning (RLHF): Entrenamiento de ChatGPT utilizando retroalimentación de evaluadores.



De Gigantes a Compactos: Descalando Modelos de Lenguaje

Unidad 8: Distillation, Especialización y Reasoning

- **Desafíos LLMs:**
 - Costos computacionales elevados
 - Consumo de energía
 - Accesibilidad limitada
 - Escasez Hardware
- **Destilación del conocimiento:** Transferencia de información de un modelo grande a uno más pequeño, manteniendo rendimiento con menor tamaño y complejidad.



Agentic AI

Temas principales:

- **Prompt Engineering:** Extracción estructurada de información (SEC filings), validación y pipelines.
- **RAG:** Retrieval-Augmented Generation con vector databases, embeddings y evaluación.
- **Tools & Agentic RAG:** Function calling, ReAct, ejecución secuencial vs paralela.
- **MCP & Sistemas Multi-Agente:** Model Context Protocol, memoria, planning, comunicación A2A.
- **Producción & LLMOps:** Latencia, guardrails, monitoreo, HITL y despliegue.

Algunos Ejemplos TPs

(de cursos pasados)

-
1. Prediccion de paros de colectivos
 - Scrapear las noticias del dia y determinar si hay algun paro de alguna linea de colectivo.
 2. Linkear codigo en github a papers
 - Dados papers y sus repositorios linear porciones del paper al codigo implementando esa seccion.
 3. Moral aligment in LLMs
 - Estudiar preferencias morales de los LLMS (paper aceptado en EMNLP) [<https://aclanthology.org/2024.emnlp-main.1224/>]
 4. Especializacion de modelos en lenguajes de bajos recursos
 5. Entrenar al modelo para canciones de cancha
 6. Generacion de titulos de noticias de alto engagement
 7. Estructurar datos de menues de pedidos ya
 - Estructurar la data interna de los menues (de texto corrido a JSON)
 8. Anonimizacion de Fallos Judiciales
 - Remover entidades que deberian ser anonimas (testigos, victimas, etc) de fallos judiciales.
-

9. Fine-tuning para prompt optimization

- Fine tune un modelo de 3B de parámetros para que mejore los prompts.

10. Generación de Knowledge-Graphs para narrativa

- Generar un KG para novelas, cuentos, etc.

11. Detección de discurso de odio en twitter

12. Asistente para generación de informes de recursos humanos

- Dada una entrevista con un candidato generar el reporte

13. Fine-tuning de GPT-2 para consultas acerca de salud mental

- Entrenar el modelo para especializarse en consultas psicológicas

14. Ortogonalizando Lenguajes

- Descubrir features (vectores) del modelo que generar comportamientos o personalidades diferentes (un modelo que siempre esta depre, uno que nunca niega, uno que responde en un solo idioma, etc.).

15. Detección de Amarillismo

- Detectar amarillismo en artículos periodísticos

16. Resúmenes de reseñas en Mercado Libre

- Dadas distintas reseñas de mercado libre generar un resumen del producto

18. Detección de personas con enfermedad de Alzheimer

19. Chess NLP

- Entrenar un modelo para jugar Ajedrez

20. LLM-ASR

21. Modelo Multimodal Texto/Audio

- Entrenar un modelo multimodal texto-audio

22. RAGs diversos (noticias, regulaciones nucleares, apuntes, leyes, etc.)

23. Edg GPT- Fine tuning GPT para contestar sarcásticamente con data sintética

24. Generador de letras de canciones.

- Modelo fine tuneado para generar letras con el estilo de cantantes determinados

25. Extracción de features mono semánticas en un transformer

- Estudiar las activaciones de la matriz de atención para descubrir el topico del input

26. Generación de guines de Bob Esponja

27. Democracia

- Agente de debate político para redacción de leyes

20. Agente de investigación Biomedica

21. Asistente UDESA

22. Asistente Legal para Jueces

23. Asistente Financiero

24. Relator de Fútbol

25. Generador de playlist en Spotify

-
- 26. GPTune your emotions
 - 27. Asistente personal
 - 28. Predictor de Bitcoin
 - 30. Texto a SQL.
 - 31. Chatbot de ventas
 - 32. Active Learners are efficient rerankers
 - *Submitido a ACL*
 - 33. Escribí como María Elena Walsh
 - 34. Predecir complejidad y latencia para LLMs sustentables
 - 35. Data sintética multimodal para autonomous driving instructions

Proyectos

- 36. FT de un LLM para que responda como un chat-bot gaucho
- 37. Obtener embeddings que capturen el comportamiento de un objeto y representen una entidad del dominio
- 38. Chat para recomendar lugares para comer usando RAG
- 39. LLM finetuneado en author imitation + sistema de agentes para escritura de libros
- 40. Chatbot para recomendación de películas
- 41. Detección de clickbait en títulos de noticias
- 42. Optimización de inferencia en LLMs mediante técnicas de skipping y early exit

Proyectos

- 43. Modelo con mecanismos de atención para identificar noticias relevantes para predecir el valor del ICG
- 44. Alucinaciones generativas como puente semántico para mejorar búsquedas vectoriales
- 45. Estudio de la generación y clasificación de texto sarcástico
- 46. Uso de GRPO para entrenamiento de un modelo que juegue ajedrez razonando
- 47. Detección de oportunidades de arbitraje en prediction markets usando LLM's con RAG y Knowledge-Graph