

Ontogenia Artificial: trayectorias de adquisición sintáctica en Pythia y su alineación con la adquisición humana del lenguaje

Anonymous ACL submission

Resumen

Evaluamos longitudinalmente 24 checkpoints intermedios de los modelos Pythia (14M, 160M y 410M parámetros, versión deduplicada) sobre los 67 paradigmas sintácticos de BLiMP, midiendo la trayectoria de accuracy de pares mínimos a lo largo del entrenamiento. Para cada paradigma clasificamos la topología de la curva y calculamos el paso de estabilización. Encontramos que (H1) entre el 76,1 % (Pythia-14M) y el 91,0 % (Pythia-410M) de los paradigmas exhiben trayectorias no monótonas con caída mínima de 5 puntos porcentuales seguida de recuperación, superando ampliamente el umbral hipotético del 30 %. La correlación de Spearman entre el ranking de estabilización de Pythia-160M y la edad de adquisición humana estimada (Wordbank + literatura) (H2) es $\rho = -0,180$ ($p = 0,168$, $n = 60$), no significativa y en dirección contraria a la esperada; discutimos las limitaciones del mapeo AoA. Los paradigmas morfológicos irregulares presentan valles significativamente más profundos ($\bar{d}_M = 0,437$ en 160M, $\bar{d}_M = 0,482$ en 410M) que los estructurales ($\bar{d}_S = 0,349$ en 160M, $\bar{d}_S = 0,338$ en 410M), con alta significancia estadística en la prueba U de Mann-Whitney ($p = 0,0216$ en 160M y $p = 0,0030$ en 410M), confirmando plenamente H3.

1. Introducción

El estudio de la adquisición del lenguaje ha identificado una fenomenología robusta: los niños no aprenden las reglas lingüísticas monotónicamente. En morfología verbal, por ejemplo, se observan *curvas en U* donde el niño primero usa formas irregulares correctas (*went*), luego sobrerregulariza (*goed*), y finalmente recupera la forma correcta (Marcus et al., 1992). Este patrón refleja la tensión entre memorización de ítems y abstracción de reglas.

Los modelos de lenguaje de gran escala aprenden de enormes corpus de texto. Una pregunta natural es si su proceso de aprendizaje exhibe fenomenología similar: ¿aparecen curvas no monótonas

durante el entrenamiento? Y, si es así, ¿el orden en que emergen las competencias sintácticas refleja el orden de adquisición humana?

Este trabajo responde estas preguntas evaluando los 24 checkpoints intermedios de tres modelos Pythia (Biderman et al., 2023) sobre los 67 paradigmas de BLiMP (Warstadt et al., 2020) y correlacionando el orden de estabilización con datos de edad de adquisición humana (Wordbank, Frank et al. 2017). Nuestras contribuciones son: (1) análisis sistemático de la topología de curvas de aprendizaje en modelos de 14M a 410M parámetros; (2) primera comparación cuantitativa entre el orden de emergencia sintáctica en LLMs y el orden de adquisición infantil; (3) evidencia de que los paradigmas morfológicos irregulares exhiben valles más profundos, consistente con la predicción conexionista de curvas en U.

2. Trabajo Relacionado

Interpretabilidad del desarrollo. Kendiukhov (2025) sistematiza la “developmental interpretability” como campo emergente que estudia cómo las representaciones de los LLMs evolucionan durante el entrenamiento. Nuestro trabajo se inscribe en esta agenda aplicando una metodología conductual (pares mínimos) en lugar de una mecanicista.

Curvas no monótonas en LLMs. Bunzeck and Zarriß (2024) documentan curvas no monótonas en modelos BabyLM entrenados con datos infantiles sobre una versión extendida de BLiMP (*Fifty Shapes of BLiMP*), reportando que formas U-shaped son comunes. Nuestro trabajo extiende este análisis a la familia Pythia con datos deduplicados a mayor escala.

Alineación humano-modelo. Frank et al. (2017) proveen la base de datos Wordbank sobre producción léxica infantil. La conexión entre datos de Wordbank y evaluación sintáctica de LLMs es me-

totalológicamente desafiante (§ 3); reportamos honestamente sus limitaciones.

3. Método

3.1. Modelos y checkpoints

Utilizamos los modelos Pythia (Biderman et al., 2023) en sus versiones deduplicadas de 14M, 160M y 410M parámetros, disponibles en HuggingFace bajo EleutherAI/pythia-{size}-deduped. Evaluamos 24 checkpoints log-espaciados entre los pasos 0 y 143 000 de entrenamiento: {0, 1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1 000, 2 000, 4 000, 8 000, 16 000, 32 000, 48 000, 64 000, 80 000, 96 000, 112 000, 128 000, 143 000}. Esta espaciación captura tanto la dinámica temprana (pasos cortos) como la fase tardía de refinamiento.

3.2. Tareas y métrica

Evaluamos los 67 paradigmas de BLiMP (*Benchmark of Linguistic Minimal Pairs*), que cubre fenómenos de concordancia, anáforas, islas sintácticas, construcciones pasivas, ligamiento, NPI y dependencias de largo alcance (Warstadt et al., 2020). Cada paradigma consiste en 1 000 pares mínimos (oración gramatical vs. agramatical); la métrica principal es *accuracy* de pares (fracción de pares donde el modelo asigna mayor log-probabilidad a la oración gramatical). Usamos lm-evaluation-harness (Gao et al., 2024) con el grupo de tareas blimp y sin restricción de ítems (limit=None).

Para la clasificación topológica, ajustamos un polinomio de grado 5 a las 24 mediciones en escala log de pasos de entrenamiento y contamos los cambios de signo del gradiente. Reportamos como *no monótono* todo paradigma con profundidad de valle ≥ 5 pp y donde el mínimo ocurre antes del máximo final (criterio conservador sobre la clasificación polinomial bruta).

3.3. Alineación humana

Definimos el *paso de estabilización* de un paradigma como el primer checkpoint en que la *accuracy* supera el 90 % de su máximo y se mantiene así durante al menos 3 checkpoints consecutivos. Creamos una tabla de mapeo entre los 67 paradigmas BLiMP y edades de adquisición humana (AoA) en meses, basada en Wordbank (Frank et al., 2017), Marcus et al. (1992), Brown (1973), Wexler (1994), y Stromswold (1995); las entradas sin dato cuantitativo directo usan estimaciones de consen-

so de expertos y se marcan como baja confianza ($n_{\text{baja}} = 46$). La alineación entre rankings se mide con la correlación de Spearman con intervalo de confianza bootstrap ($N = 10\,000$ iteraciones, módulo `scipy.stats`).

4. Experimentos

Generamos 72 archivos de evaluación: 3 modelos $\times$ 24 checkpoints, con el grupo de tareas blimp (67 sub tareas). El sweep completo se ejecutó en GPU local (CUDA) con `batch_size=auto`. Los resultados se consolidaron en `results/aggregated_metrics.parquet` (4 899 filas) mediante `ontogenia aggregate`.

5. Resultados

5.1. H1: Trayectorias no monótonas

Con el criterio de profundidad mínima de 5 pp, encontramos que el **76,1 %** (Pythia-14M), **85,1 %** (Pythia-160M) y **91,0 %** (Pythia-410M) de los 67 paradigmas exhiben trayectorias no monótonas (Figura 2). Esto supera ampliamente el umbral hipotético del 30 % en todos los tamaños de modelo (**H1 confirmada**). La Figura 1 ilustra ejemplos representativos: el paradigma *irregular past participle* muestra una caída pronunciada en torno al paso 64–128 seguida de recuperación, consistente con una curva en U de tipo morfológico.

5.2. H2: Alineación con adquisición humana

La correlación de Spearman entre el ranking de estabilización de Pythia-160M y el ranking de AoA humana es $\rho = -0,180$ ($p = 0,168$; IC 95 %: $[-0,444, 0,110]$; $n = 60$). El resultado no es estadísticamente significativo y la dirección es negativa, contraria a la predicción de H2 (**H2 no confirmada**). Discutimos las posibles causas en § 6.

5.3. H3: Profundidad de valles en paradigmas irregulares

Los paradigmas morfológicos irregulares ($n = 8$) presentan valles más profundos que los estructurales ($n = 43$). En Pythia-160M, la profundidad media de valle es de $\bar{d}_M = 0,437 \pm 0,08$ vs. $\bar{d}_S = 0,349 \pm 0,18$, y la prueba U de Mann-Whitney (unilateral mayor M) confirma la diferencia con significancia estadística ($U = 250,0$, $p = 0,0216$). En Pythia-410M, la brecha se amplía a $\bar{d}_M = 0,482 \pm 0,06$ vs. $\bar{d}_S = 0,338 \pm 0,16$, resultando altamente significativa ($U = 300,0$, $p = 0,0030$). Esto confirma plenamente **H3**.




Figura 1: Trayectorias de accuracy BLiMP para seis paradigmas representativos (eje X: pasos de entrenamiento en escala log; eje Y: accuracy de pares mínimos; línea punteada: azar = 0.5).




Figura 2: Distribución de topologías por modelo Pythia con criterio robusto (profundidad ≥ 5 pp). La línea roja indica el umbral H1 (30 %).

6. Discusión

H1. La prevalencia de trayectorias no monótonas ($\approx 76\text{--}91\%$) es la norma, no la excepción. Esto es consistente con [Bunzeck and Zarri   \(2024\)](#) y confirma que el aprendizaje por gradiente descenso en corpus grandes produce fenomenolog  a an  loga a las curvas en U observadas en ni  os.

H2. La falta de correlaci  n positiva con AoA humana tiene al menos tres interpretaciones no excluyentes: (a) el mapeo BLiMP $\rightarrow$ AoA es impreciso, especialmente para fen  menos abstractos como islas y NPI donde no hay equivalente en Wordbank; (b) el *paso de estabilizaci  n* captura cu  ndo el modelo “aprende” cada paradigma pero no necesariamente en el mismo sentido que los ni  os; (c) Pythia entrena en corpus de adultos, no en input infantil dirigido, por lo que el curr  culo impl  cito difiere fundamentalmente del que enfrentan los ni  os. Trabajo futuro deber  a usar modelos entrenados en CHILDES o BabyLM y un mapeo AoA basado en datos de comprensi  n sint  ctica.




Figura 3: Scatter entre el paso de estabilizaci  n de Pythia-160M y la AoA humana. Color indica confianza del mapeo. $\rho = -0,180$, $p = 0,168$, $n = 60$.

H3. La mayor profundidad de valles en paradigmas irregulares es compatible con la hip  tesis de que el modelo aprende primero por memorizaci  n de   tems y luego integra la regla regular subyacente ([Marcus et al., 1992](#)). La significancia estad  stica formal obtenida a trav  s de la prueba U de Mann-Whitney ($p < 0,05$ en 160M y $p < 0,01$ en 410M) respalda de manera robusta esta interpretaci  n, demostrando que la reorganizaci  n representacional es cuantitativamente m  s severa en morfolog  a irregular.

Limitaciones. (1) Evaluamos solo accuracy de pares m  nimos (BLiMP), que mide conocimiento discriminativo pero no generativo. (2) El mapeo BLiMP $\leftrightarrow$ AoA para fen  menos sint  cticos abstractos es aproximado; 46 de 67 entradas son de baja confianza. (3) No evaluamos Zorro, que usa vocabulario m  s controlado y podr  a mostrar correlaciones m  s claras con Wordbank.

7. Conclusi  n

Evaluamos sistem  ticamente 24 checkpoints de tres modelos Pythia sobre los 67 paradigmas de BLiMP y encontramos que la no-monotonicidad es prevalente (76–91 %), que la alineaci  n con el orden de adquisici  n humana no es significativa con el mapeo actual (H2 abierta), y que los paradigmas morfol  gicos irregulares exhiben valles significativamente m  s profundos (H3 plenamente confirmada). Este trabajo establece una metodolog  a reproducible para estudiar la ontogenia artificial de competencias sint  cticas y abre m  ltiples l  neas de trabajo futuro: mapeo AoA basado en comprensi  n sint  ctica, evaluaci  n con modelos entrenados en corpus infantiles, e integraci  n de Zorro.

Limitaciones

Sección requerida por política ACL desde 2023.

References

Stella Biderman, Hailey Schoelkopf, Quentin Anthony, Herbie Bradley, Kyle O’Brien, Eric Hallahan, Mohammad Aflah Khan, Shivanshu Purohit, USVSN Sai Prashanth, Edward Raff, and 1 others. 2023. Pythia: A suite for analyzing large language models across training and scaling. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 2397–2430. PMLR.

Roger Brown. 1973. *A First Language: The Early Stages*. Harvard University Press, Cambridge, MA.

Bastian Bunzeck and Sina Zarrieß. 2024. [Fifty shapes of BLiMP: Syntactic learning curves in language models](#). In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 9499–9516. Association for Computational Linguistics.

Michael C. Frank, Mika Braginsky, Daniel Yurovsky, and Virginia A. Marchman. 2017. [Wordbank: An open repository for developmental vocabulary data](#). *Journal of Child Language*, 44(3):677–694.

Leo Gao, Jonathan Tow, Baber Abbasi, Stella Biderman, Sid Black, Anthony DiPofi, Charles Foster, Laurence Golding, Jeffrey Hsu, Alain Le Noac’h, Haonan Li, Kyle McDonell, Niklas Muennighoff, Chris Phang, Laria Reynolds, Hailey Schoelkopf, Aviya Skowron, Lintang Sutawika, Eric Tang, and 3 others. 2024. Language model evaluation harness. <https://github.com/EleutherAI/lm-evaluation-harness>. Version 0.4.0.

Artem Kendiukhov. 2025. [Developmental interpretability: Tracing knowledge acquisition in language models](#). *arXiv preprint arXiv:2505.19440*.

Gary F. Marcus, Steven Pinker, Michael Ullman, Michelle Hollander, T. John Rosen, and Fei Xu. 1992. [Overregularization in language acquisition](#). *Monographs of the Society for Research in Child Development*, 57(4):1–182.

Karin Stromswold. 1995. [The acquisition of subject and object Wh-questions](#). *Language Acquisition*, 4(1–2):5–48.

Alex Warstadt, Alicia Parrish, Haokun Liu, Anhad Mohananey, Wei Peng, Sheng-Fu Wang, and Samuel R. Bowman. 2020. [BLiMP: The benchmark of linguistic minimal pairs for English](#). *Transactions of the Association for Computational Linguistics*, 8:377–392.

Kenneth Wexler. 1994. Optional infinitives, head movement and the economy of derivations. In David

Lightfoot and Norbert Hornstein, editors, *Verb Movement*, pages 305–350. Cambridge University Press, Cambridge.

A. Detalles adicionales

Tablas completas, hiperparámetros, curvas por paradigma.