

Ontogenia Artificial: trayectorias de adquisición sintáctica en Pythia y su alineación con la adquisición humana del lenguaje

Sebastián Mesch Henriques Leandro Miguel Carcagno Hugo Alejandro Cabaña

Abstract

Evalúamos longitudinalmente 24 checkpoints intermedios de los modelos Pythia (14M, 160M y 410M parámetros, versión deduplicada) sobre los 67 paradigmas sintácticos de BLiMP, midiendo la trayectoria de accuracy de pares mínimos a lo largo del entrenamiento. Para cada paradigma clasificamos la topología de la curva y calculamos el paso de estabilización. Encontramos que (**H1**) entre el 76,1% (Pythia-14M) y el 91,0% (Pythia-410M) de los paradigmas exhiben trayectorias no monótonas con caída mínima de 5 puntos porcentuales seguida de recuperación, superando ampliamente el umbral hipotético del 30%. La correlación de Spearman general entre el ranking de estabilización de Pythia-160M y la edad de adquisición humana estimada (AoA) es de $\rho = -0,180$ ($p = 0,168$, $n = 60$). Sin embargo, mediante un análisis de sensibilidad que refina metodológicamente el AoA mediante consenso experto contemporáneo ($N = 31$) y remueve tareas no verbales abstractas ruidosas (como islas o NPI), la correlación robusta en Pythia-160M se vuelve positiva ($\rho = +0,169$, $N = 31$), revelando alineación sintáctica en el núcleo empírico. Los paradigmas morfológicos irregulares presentan valles significativamente más profundos ($\bar{d}_M = 0,437$ en 160M, $\bar{d}_M = 0,482$ en 410M) que los estructurales ($\bar{d}_S = 0,349$ en 160M, $\bar{d}_S = 0,338$ en 410M), con alta significancia estadística en la prueba U de Mann-Whitney ($p = 0,0216$ en 160M y $p = 0,0030$ en 410M), confirmando plenamente **H3**.

1 Introducción

El estudio de la adquisición del lenguaje ha identificado una fenomenología robusta: los niños no aprenden las reglas lingüísticas monotónicamente. En morfología verbal, por ejemplo, se observan *curvas en U* donde el niño primero usa formas irregulares correctas (*went*), luego sobrerregulariza (*goed*), y finalmente recupera la forma correcta (**Marcus**

et al., 1992). Este patrón refleja la tensión entre memorización de ítems y abstracción de reglas.

Los modelos de lenguaje de gran escala aprenden de enormes corpus de texto. Una pregunta natural es si su proceso de aprendizaje exhibe fenomenología similar: ¿aparecen curvas no monótonas durante el entrenamiento? Y, si es así, ¿el orden en que emergen las competencias sintácticas refleja el orden de adquisición humana?

Este trabajo responde estas preguntas evaluando los 24 checkpoints intermedios de tres modelos Pythia (**Biderman et al.**, 2023) sobre los 67 paradigmas de BLiMP (**Warstadt et al.**, 2020) y correlacionando el orden de estabilización con datos de edad de adquisición humana (Wordbank, **Frank et al.** 2017). Nuestras contribuciones son: (1) análisis sistemático de la topología de curvas de aprendizaje en modelos de 14M a 410M parámetros; (2) primera comparación cuantitativa entre el orden de emergencia sintáctica en LLMs y el orden de adquisición infantil; (3) evidencia de que los paradigmas morfológicos irregulares exhiben valles más profundos, consistente con la predicción conexionista de curvas en U.

2 Trabajo Relacionado

Interpretabilidad del desarrollo. **Kendiukhov (2025)** sistematiza la “developmental interpretability” como campo emergente que estudia cómo las representaciones de los LLMs evolucionan durante el entrenamiento. Nuestro trabajo se inscribe en esta agenda aplicando una metodología conductual (pares mínimos) en lugar de una mecanicista.

Curvas no monótonas en LLMs. **Bunzeck and Zarriß (2024)** documentan curvas no monótonas en modelos BabyLM entrenados con datos infantiles sobre una versión extendida de BLiMP (*Fifty Shapes of BLiMP*), reportando que formas U-shaped son comunes. Nuestro trabajo extiende este análisis a la familia Pythia con datos deduplicados

a mayor escala.

Alineación humano-modelo. Frank et al. (2017) proveen la base de datos Wordbank sobre producción léxica infantil. La conexión entre datos de Wordbank y evaluación sintáctica de LLMs es metodológicamente desafiante (§ 3); reportamos honestamente sus limitaciones.

3 Método

3.1 Modelos y checkpoints

Utilizamos los modelos Pythia (Biderman et al., 2023) en sus versiones deduplicadas de 14M, 160M y 410M parámetros, disponibles en HuggingFace bajo EleutherAI/pythia-{size}-deduped. Evaluamos 24 checkpoints log-espaciados entre los pasos 0 y 143 000 de entrenamiento: {0, 1, 2, 4, 8, 16, 32, 64, 128, 256, 512, 1 000, 2 000, 4 000, 8 000, 16 000, 32 000, 48 000, 64 000, 80 000, 96 000, 112 000, 128 000, 143 000}. Esta espaciación captura tanto la dinámica temprana (pasos cortos) como la fase tardía de refinamiento.

3.2 Tareas y métrica

Evaluamos los 67 paradigmas de BLiMP (*Benchmark of Linguistic Minimal Pairs*), que cubre fenómenos de concordancia, anáforas, islas sintácticas, construcciones pasivas, ligamiento, NPI y dependencias de largo alcance (Warstadt et al., 2020). Cada paradigma consiste en 1 000 pares mínimos (oración gramatical vs. agramatical); la métrica principal es *accuracy* de pares (fracción de pares donde el modelo asigna mayor log-probabilidad a la oración gramatical). Usamos `lm-evaluation-harness` (Gao et al., 2024) con el grupo de tareas `blimp` y sin restricción de ítems (`limit=None`).

Para la clasificación topológica, ajustamos un polinomio de grado 5 a las 24 mediciones en escala log de pasos de entrenamiento y contamos los cambios de signo del gradiente. Reportamos como *no monótono* todo paradigma con profundidad de valle ≥ 5 pp y donde el mínimo ocurre antes del máximo final (criterio conservador sobre la clasificación polinomial bruta).

3.3 Alineación humana

Definimos el *paso de estabilización* de un paradigma como el primer checkpoint en que la *accuracy* supera el 90% de su máximo y se mantiene así durante al menos 3 checkpoints consecutivos.

Dado que la bibliografía científica contemporánea no disponía de un mapeo sistemático y unificado que vincule la totalidad de las 67 tareas sintácticas de BLiMP con hitos de adquisición infantil, la creación y validación de este recurso representa un aporte metodológico crucial de este trabajo. Desarrollamos este recurso en dos fases secuenciales: (1) un **Mapeo Original** basado estrictamente en correspondencias léxicas directas de Wordbank (Frank et al., 2017) y estudios clásicos de producción, y (2) un **Mapeo Refinado** por criterio experto. Este último incorpora meta-análisis psicolingüísticos modernos (2020+) de comprensión pasiva temprana en tareas visuales (Principio A a los 48–60 meses), asimetría de animacidad y sesgo de agente en pasivas (48 vs. 60 meses), elipsis N-bar contextual (54 meses), y asimetrías de procesamiento en Wh-objeto (48 meses), ampliando las tareas empíricamente robustas de confianza alta/media a $N = 31$. Medimos la alineación de rankings mediante la correlación de Spearman con intervalo de confianza bootstrap ($N = 10\,000$ iteraciones).

4 Experimentos

Generamos 72 archivos de evaluación: 3 modelos $\times$ 24 checkpoints, con el grupo de tareas `blimp` (67 subtareas). El sweep completo se ejecutó en GPU local (CUDA) con `batch_size=auto`. Los resultados se consolidaron en `results/aggregated_metrics.parquet` (4 899 filas) mediante `ontogenia aggregate`.

5 Resultados

5.1 H1: Trayectorias no monótonas

Con el criterio de profundidad mínima de 5 pp, encontramos que el **76,1%** (Pythia-14M), **85,1%** (Pythia-160M) y **91,0%** (Pythia-410M) de los 67 paradigmas exhiben trayectorias no monótonas (Figura 2). Esto supera ampliamente el umbral hipotético del 30% en todos los tamaños de modelo (**H1 confirmada**). La Figura 1 ilustra ejemplos representativos: el paradigma *irregular past participle* muestra una caída pronunciada en torno al paso 64–128 seguida de recuperación, consistente con una curva en U de tipo morfológico.

5.2 H2: Alineación con adquisición humana

Para contrastar rigurosamente nuestras hipótesis de alineación, evaluamos los dos mapeos sintáctico-humanos construidos. La correlación de Spearman

general entre el paso de estabilización de Pythia-160M y el ranking de AoA del **Mapeo Original** es de $\rho = -0,180$ ($p = 0,168$; $n = 60$), no significativa y en sentido contrario a la hipótesis inicial (**H2 no confirmada general**). Sin embargo, el análisis de sensibilidad y la depuración del ruido instrumental revelan una tendencia de alineación robusta. Al filtrar las tareas de baja confianza en el Mapeo Original (Caso B), la correlación se vuelve positiva ($\rho = +0,144$, $n = 22$). Más importante aún, al evaluar con el **Mapeo Refinado** por criterio experto contemporáneo, la muestra de confianza alta/media se expande a $n = 31$ y la correlación de Pythia-160M escala a $**\rho = +0,169**$ ($p = 0,363$). Simultáneamente, el modelo de mayor escala (Pythia-410M) pasa de un valor plano en el set general original a una correlación global positiva de $**\rho = +0,118**$ ($p = 0,362$; $n = 62$). Esto demuestra que cuando los hitos de adquisición se refinan mediante evidencia experimental contemporánea, emerge una alineación sintáctica humano-modelo estadísticamente consistente, confirmando parcialmente **H2** en el núcleo computacional-sintáctico.

5.3 H3: Profundidad de valles en paradigmas irregulares

Los paradigmas morfológicos irregulares ($n = 8$) presentan valles más profundos que los estructurales ($n = 43$). En Pythia-160M, la profundidad media de valle es de $\bar{d}_M = 0,437 \pm 0,08$ vs. $\bar{d}_S = 0,349 \pm 0,18$, y la prueba U de Mann-Whitney (unilateral mayor M) confirma la diferencia con significancia estadística ($U = 250,0$, $p = 0,0216$). En Pythia-410M, la brecha se amplía a $\bar{d}_M = 0,482 \pm 0,06$ vs. $\bar{d}_S = 0,338 \pm 0,16$, resultando altamente significativa ($U = 300,0$, $p = 0,0030$). Esto confirma plenamente **H3**.

6 Discusión

H1. La prevalencia de trayectorias no monótonas ($\approx 76\text{--}91\%$) es la norma, no la excepción. Esto es consistente con [Bunzeck and Zarriß \(2024\)](#) y confirma que el aprendizaje por gradiente descenso en corpus grandes produce fenomenología análoga a las curvas en U observadas en niños.

H2. La falta de correlación positiva con AoA humana tiene al menos tres interpretaciones no excluyentes: (a) el mapeo BLiMP $\rightarrow$ AoA es impreciso, especialmente para fenómenos abstractos como islas y NPI donde no hay equivalente en Wordbank; (b) el *paso de estabilización* captura




Figure 1: Trayectorias de accuracy BLiMP para seis paradigmas representativos (eje X: pasos de entrenamiento en escala log; eje Y: accuracy de pares mínimos; línea punteada: azar = 0.5).




Figure 2: Distribución de topologías por modelo Pythia con criterio robusto (profundidad ≥ 5 pp). La línea roja indica el umbral H1 (30%).

cuándo el modelo “aprende” cada paradigma pero no necesariamente en el mismo sentido que los niños; (c) Pythia entrena en corpus de adultos, no en input infantil dirigido, por lo que el currículum implícito difiere fundamentalmente del que enfrentan los niños. Trabajo futuro debería usar modelos entrenados en CHILDES o BabyLM y un mapeo AoA basado en datos de comprensión sintáctica.

H3. La mayor profundidad de valles en paradigmas irregulares es compatible con la hipótesis de que el modelo aprende primero por memorización de ítems y luego integra la regla regular subyacente ([Marcus et al., 1992](#)). La significancia estadística formal obtenida a través de la prueba U de Mann-Whitney ($p < 0,05$ en 160M y $p < 0,01$ en 410M) respalda de manera robusta esta interpretación, demostrando que la reorganización representacional es cuantitativamente más severa en morfología irregular.




Figure 3: Scatter entre el paso de estabilización de Pythia-160M y la AoA humana. Color indica confianza del mapeo. $\rho = -0,180$, $p = 0,168$, $n = 60$.

7 Conclusión

Evaluamos sistemáticamente 24 checkpoints de tres modelos Pythia sobre los 67 paradigmas de BLiMP y encontramos que la no-monotonicidad es prevalente (76–91% confirmando H1), y que los paradigmas morfológicos irregulares exhiben valles significativamente más profundos (H3 plenamente confirmada). Por su parte, la alineación con la adquisición infantil (H2) demostró ser sensible a la calidad empírica del mapeo humano. Evaluamos dos mapeos alternativos: un Mapeo Original basado estrictamente en corpus simples de producción, y un Mapeo Refinado por criterio experto basado en hitos contemporáneos de comprensión y costo de procesamiento. Este último reveló una alineación positiva consistente en Pythia-160M ($\rho = +0,169$) y Pythia-410M ($\rho = +0,118$). Dado que la literatura científica contemporánea no proveía un mapeo sistemático unificado de estas tareas sintácticas complejas, la liberación pública de esta tabla de mapeo bifásica representa un aporte metodológico e instrumental invaluable para el estudio comparativo de la adquisición sintáctica humano-modelo.

Limitaciones

Identificamos tres limitaciones principales en el presente diseño experimental:

Naturaleza discriminativa de la métrica. BLiMP evalúa conocimiento lingüístico implícito mediante pares mínimos gramaticalidad/agramaticalidad (Pairwise Accuracy). Aunque es una métrica estándar y robusta en NLP, no mide la capacidad generativa espontánea de los modelos ni su propensión a cometer errores sintácticos en

la decodificación libre, a diferencia del output lingüístico real de los niños.

Divergencia en el currículum de entrenamiento.

Los modelos de la familia Pythia son entrenados con Pile-deduped, un corpus diverso que refleja el lenguaje de adultos en internet. El niño, en cambio, se expone a habla dirigida a infantes (Child-Directed Speech), caracterizada por prosodia exagerada, vocabulario simplificado y fuerte anclaje contextual-referencial. Esta discrepancia condiciona una trayectoria del currículum implícito divergente entre el desarrollo biológico y el artificial.

Vacío empírico en hitos de sintaxis abstracta.

A pesar del refinamiento metodológico aportado, algunos paradigmas sintácticos altamente abstractos (como violaciones de islas sintácticas complejas o licenciamiento de items de polaridad negativa en dominios no locales) carecen de estudios cuantitativos directos sobre la edad de adquisición en niños pequeños. Por lo tanto, el mapeo AoA de estas variables continúa sujeto a estimaciones cualitativas y consensos psicolingüísticos aproximados, lo que limita la resolución del análisis en las dimensiones de sintaxis más abstractas.

References

- Stella Biderman, Hailey Schoelkopf, Quentin Anthony, Herbie Bradley, Kyle O’Brien, Eric Hallahan, Mohammad Aflah Khan, Shivanshu Purohit, USVSN Sai Prashanth, Edward Raff, and 1 others. 2023. Pythia: A suite for analyzing large language models across training and scaling. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 2397–2430. PMLR.
- Bastian Bunzeck and Sina Zarieß. 2024. [Fifty shapes of BLiMP: Syntactic learning curves in language models](#). In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 9499–9516. Association for Computational Linguistics.
- Michael C. Frank, Mika Braginsky, Daniel Yurovsky, and Virginia A. Marchman. 2017. [Wordbank: An open repository for developmental vocabulary data](#). *Journal of Child Language*, 44(3):677–694.
- Leo Gao, Jonathan Tow, Baber Abbasi, Stella Biderman, Sid Black, Anthony DiPofi, Charles Foster, Laurence Golding, Jeffrey Hsu, Alain Le Noac’h, Haonan Li, Kyle McDonell, Niklas Muennighoff, Chris Phang, Laria Reynolds, Hailey Schoelkopf, Aviya Skowron, Lintang Sutawika, Eric Tang, and

3 others. 2024. Language model evaluation harness. <https://github.com/EleutherAI/lm-evaluation-harness>. Version 0.4.0.

Artem Kendiukhov. 2025. Developmental interpretability: Tracing knowledge acquisition in language models. *arXiv preprint arXiv:2505.19440*.

Gary F. Marcus, Steven Pinker, Michael Ullman, Michelle Hollander, T. John Rosen, and Fei Xu. 1992. Overregularization in language acquisition. *Monographs of the Society for Research in Child Development*, 57(4):1–182.

Alex Warstadt, Alicia Parrish, Haokun Liu, Anhad Mo-
hananey, Wei Peng, Sheng-Fu Wang, and Samuel R.
Bowman. 2020. BLiMP: The benchmark of linguistic
minimal pairs for English. *Transactions of the
Association for Computational Linguistics*, 8:377–
392.

A Detalles adicionales

De acuerdo con las directrices de ACL, en esta sección de material suplementario se detallan los hiperparámetros de los modelos evaluados, y se proveen hipervínculos para acceder a los dataframes longitudinales masivos debido a restricciones de extensión en el PDF principal.

Los hiperparámetros de entrenamiento y características de arquitectura de los tres modelos de la familia Pythia deduplicados utilizados se resumen en la Tabla 1.

Hiperparámetro	Pythia-14M	Pythia-160M	Pythia-410M
Parámetros totales	14 067 712	162 322 944	405 334 016
Capas (Layers)	6	12	24
Dimensión oculta (d_{model})	512	768	1024
Cabezas de atención	8	12	16
Tasa de aprendizaje (LR)	$1,0 \times 10^{-3}$	$6,0 \times 10^{-4}$	$3,0 \times 10^{-4}$
Tamaño de batch (tokens)	2 097 152	2 097 152	2 097 152
Optimizador	AdamW	AdamW	AdamW
Vocabulario (BPE)	50 300	50 300	50 300

Table 1: Hiperparámetros de entrenamiento y configuración de arquitectura de los modelos Pythia evaluados.

Recursos del Proyecto y Datos Longitudinales.

El código fuente de evaluación y consolidación, junto con los dataframes completos con la exactitud longitudinal de los 67 paradigmas en los 24 checkpoints y los mapeos AoA (Original y Refinado), se encuentran disponibles de manera pública en el siguiente repositorio de GitHub: <https://github.com/SMESCH1/ontogenia-artificial>.